

Vysoká škola ekonomická v Praze  
Fakulta informatiky a statistiky



# **Variační autoenkodér a úlohy pozorování v latentním prostoru**

## **BAKALÁŘSKÁ PRÁCE**

Studijní program: Aplikovaná informatika

Autor: Tomáš Faltejsek

Vedoucí práce: Ing. Ondřej Vadinský, Ph.D.

Konzultant práce: full consultant's name (incl. degrees)

Praha, květen 2023

## **Poděkování**

Thanks.

## **Abstract**

Jedním z předních rysů lidské inteligence je intuice a schopnost představovat si nové objekty. Variační autoenkodér je inovací na poli pravděpodobnostních modelů, umožňující architekturu modelů schopných syntézy zcela nových dat s využitím pozorování atributů v latentním prostoru. Teoretická charakteristika a možnosti využití variačního autoenkodéru jsou předmětem této bakalářské práce.

## **Keywords**

keyword, important term, another topic, and another one

# Obsah

Úvod	9
<b>1 Východiska variačního autoenkodéru</b>	<b>10</b>
1.1 Umělé neuronové sítě . . . . .	11
1.1.1 Perceptron . . . . .	11
1.1.2 Hebbovské učení . . . . .	11
1.1.3 Universal approximation theorem . . . . .	11
1.1.4 Vícevrstvý Perceptron . . . . .	11
1.1.5 Gradient descent . . . . .	11
1.1.6 Backpropagation . . . . .	11
1.1.7 Strojové učení . . . . .	11
1.1.8 Hluboké učení . . . . .	11
1.1.9 Konvoluční sítě . . . . .	11
1.2 Redukce dimenzionality . . . . .	12
1.2.1 The Curse of Dimensionality . . . . .	12
1.2.2 Analýza hlavních komponent . . . . .	12
1.3 Autoenkodér . . . . .	13
1.3.1 Historický pohled . . . . .	13
1.3.2 Neuplný autoenkodér // Undercomplete Autoencoder . . . . .	14
1.3.3 Hluboký autoenkodér . . . . .	14
1.3.4 Řídký autoenkodér . . . . .	14
1.3.5 Denoising autoenkodér . . . . .	14
1.3.6 Contractive autoenkodér . . . . .	14
1.3.7 Stochastický enkodér dekodér . . . . .	14
1.3.8 Od Analýzy hlavních komponent po Autoenkodér . . . . .	14
1.3.9 Taxonomie autoenkodérů . . . . .	14
1.4 Pravděpodobnostní modely a inference pomocí variačního Bayese . . . . .	15
1.5 Kullback–Lieblerova divergence . . . . .	16
1.6 Modely využívající latentních proměnných // Latent Variable Models . . . . .	17
<b>2 Variační autoenkodér</b>	<b>18</b>
2.1 Evidence Lower Bound . . . . .	18
2.2 Reparametrizační trik . . . . .	18
2.3 Formalizace . . . . .	18
2.4 Model umělé neuronové sítě . . . . .	18
2.5 Nedostatky a omezení . . . . .	18
2.6 Rozšíření a aktuální stav poznání . . . . .	18
2.7 Pozorování v latentním prostoru . . . . .	18
<b>3 Úlohy pozorování v latentním prostoru</b>	<b>19</b>

3.1	Generativní modelování obrazových dat . . . . .	19
3.2	Rekonstrukce obrazových dat . . . . .	19
3.3	Interpolace vět . . . . .	19
3.4	Detekce anomálií . . . . .	19
3.5	Syntéza tabulárních dat . . . . .	19
3.6	Kompresa . . . . .	19
<b>4</b>	<b>Experimenty s modelem variačního autoenkodéru</b>	<b>20</b>
4.1	Generativní modelování obrazových dat . . . . .	20
4.1.1	Vymezení problémové oblasti . . . . .	20
4.1.2	Datová sada a předzpracování . . . . .	20
4.1.3	Nastavení experimentu . . . . .	20
4.1.4	Návrh modelu . . . . .	20
4.1.5	Evaluační . . . . .	20
4.1.6	Diskuze . . . . .	20
4.2	Interpolace vět . . . . .	20
	<b>Závěr</b>	<b>21</b>
<b>A</b>	<b>Zdrojové kódy modelů</b>	<b>23</b>

# Seznam obrázků

1.1	Obecná struktura Autoenkodéru, mapující vstup $\mathbf{x}$ na rekonstrukci $\mathbf{r}$ skrze vnitřní reprezentaci ( <i>kód</i> ) $\mathbf{h}$ . . . . .	13
-----	--	----

Note: Add a list of figures if the number of figures in the thesis text exceeds 20. A list of diagrams is applicable only if the author distinguishes between a figure and a diagram. The list of diagrams is included if the number of diagrams exceeds 20. This thesis template does not distinguish between a figure and a diagram.

# Seznam tabulek

Note: Add a list of tables if the number of tables used in the thesis exceeds 20.

# Seznam použitých zkratk

**BCC** Blind Carbon Copy

**CC** Carbon Copy

**CERT** Computer Emergency Response  
Team

**CSS** Cascading Styleheets

**DOI** Digital Object Identifier

**HTML** Hypertext Markup Language

**REST** Representational State Transfer

**SOAP** Simple Object Access Protocol

**URI** Uniform Resource Identifier

**URL** Uniform Resource Locator

**XML** eXtended Markup Language

Note: Add a list of abbreviations if the number of abbreviations used in the thesis exceeds 20 and the abbreviations used are not common.



# Úvod

Introduction is a compulsory part of the bachelor's / diploma thesis. The introduction is an introduction to the topic. It elaborates the chosen topic, briefly puts it into context (there may also be a description of the motivation to write the work) and answers the question why the topic was chosen. It puts the topic into context and justifies its necessity and the topicality of the solution. It contains an explicit goal of the work. The text of the thesis goal is identical with the text that is given in the bachelor's thesis assignment, ie with the text that is given in the InSIS system and which is also given in the Abstract section.

Part of the introduction is also a brief introduction to the process of processing the work (a separate part of the actual text of the work is devoted to the method of processing). The introduction may also include a description of the motivation to write the work.

The introduction to the diploma thesis must be more elaborate - this is stated in more detail in the Requirements of the diploma thesis within the Intranet for FIS students.

Here are some sample chapters that recommend how a bachelor's / master's thesis should be set. They primarily describe the use of the L<sup>A</sup>T<sub>E</sub>X template, but general advice will also serve users of other systems well.

# **1. Východiska variačního autoenkodéru**

## **1.1 Umělé neuronové sítě**

### **1.1.1 Perceptron**

### **1.1.2 Hebbovské učení**

### **1.1.3 Universal approximation theorem**

### **1.1.4 Vícevrstvý Perceptron**

### **1.1.5 Gradient descent**

### **1.1.6 Backpropagation**

### **1.1.7 Strojové učení**

### **1.1.8 Hluboké učení**

### **1.1.9 Konvoluční sítě**


## **1.2 Redukce dimenzionality**

### **1.2.1 The Curse of Dimensionality**

### **1.2.2 Analýza hlavních komponent**

## 1.3 Autoenkodér

Autoenkodér je typ umělé neuronové sítě schopný učit se efektivní reprezentace vstupních dat bez učitele. Umělá neuronová síť Autoenkodéru má symetrickou strukturu a skrytou vrstvu  $h$ , která popisuje *kód* použitý pro reprezentaci vstupu. Architekturu sítě lze principiálně rozdělit na dvě části – kódovací funkci  $h = f(x)$ , resp. **enkodér** a dekodovací funkci  $r = g(h)$ , resp. **dekodér** (výstupem dekodéru je rekonstrukce vstupu  $r$ ).



Obrázek 1.1: Obecná struktura Autoenkodéru, mapující vstup  $x$  na rekonstrukci  $r$  skrze vnitřní reprezentaci (*kód*)  $h$ .

Autoenkodér má typicky totožnou architekturu jako Vícevrstvý Perceptron subsection 1.1.4, s výjimkou rovnosti počtu neuronů ve výstupní vrstvě s počtem vstupů umělé neuronové sítě.

### 1.3.1 Historický pohled

Vícevrstvý Perceptron subsection 1.1.4 je univerzálním aproximátorem subsection 1.1.3 – tedy historicky nalézá uplatnění zejména v klasifikačních úlohách učení s učitelem. Sofistikovaný algoritmus se schopností trénování Vícevrstvého Perceptronu s větším počtem skrytých vrstev stále schází, a to zejména v důsledku problému mizejícího gradientu (*vanishing gradient problem*). Až příchod algoritmu gradientního sestupu subsection 1.1.5, který adresuje problém mizejícího gradientu v aplikacích s použitím konvolučních sítí subsection 1.1.9 a úloh učení se bez učitele, značí počátek moderních metod hlubokého učení. V oblasti hlubokého učení subsection 1.1.8 dochází k emergenci a vývoji řady technik pro řešení úloh učení se bez učitele. V této kapitole je popsána pouze jedna z nich – architektura umělé neuronové sítě založené na *enkodér-dekodér* modulech: Autoenkodér. Autoenkodéry byly poprvé představeny jako způsob pro předtrénování umělých neuronových sítí (formou automatizované extrakce vlastností *feature extraction*). Později Autoenkodéry nalézají uplatnění zejména v úlohách redukce dimenzionality section 1.2 či fúzi vlastností (*feature fusion*).

Nedávné teoretické propojení Autoenkodéru a Modelů využívajících latentní proměnných section 1.6 však vedlo ke vzniku zcela nové architektury neuronové sítě kombinující charakter redukce dimenzionality Autoenkodéru se statistickými metodami odvozování. To vyneslo Autoenkodéry na popředí v oblasti generativního modelování – této architektuře je věnována kapitola chapter 2.

Byť Autoenkodéry vznikly v kontextu hlubokého učení, není pravidlem že všechny modely Autoenkodéru obsahují vícero skrytých vrstev. Následuje rozdělení Autoenkodérů dle struk-

tury umělé neuronové sítě.

### **1.3.2 Neuplný autoenkodér // Undercomplete Autoencoder**

### **1.3.3 Hlubuký autoenkodér**

Hluboký autoenkodér (*stacked* autoenkodér)

### **1.3.4 Řídký autoenkodér**

### **1.3.5 Denoising autoenkodér**

### **1.3.6 Contractive autoenkodér**

### **1.3.7 Stochastický enkodér dekodér**

### **1.3.8 Od Analýzy hlavních komponent po Autoenkodér**

### **1.3.9 Taxonomie autoenkodérů**

## **1.4 Pravděpodobnostní modely a inference pomocí variačního Bayese**

## 1.5 Kullback–Lieblerova divergence



## **1.6 Modely využívající latentních proměnných // Latent Variable Models**

## **2. Variační autoenkodér**

**2.1 Evidence Lower Bound**

**2.2 Reparametrizační trik**

**2.3 Formalizace**

**2.4 Model umělé neuronové sítě**

**2.5 Nedostatky a omezení**

**2.6 Rozšíření a aktuální stav poznání**

**2.7 Pozorování v latentním prostoru**

## **3. Úlohy pozorování v latentním prostoru**

**3.1 Generativní modelování obrazových dat**

**3.2 Rekonstrukce obrazových dat**

**3.3 Interpolace vět**

**3.4 Detekce anomálií**

**3.5 Syntéza tabulárních dat**

**3.6 Komprese**

## **4. Experimenty s modelem variačního autoenkodéru**

### **4.1 Generativní modelování obrazových dat**

#### **4.1.1 Vymezení problémové oblasti**

#### **4.1.2 Datová sada a předzpracování**

#### **4.1.3 Nastavení experimentu**

#### **4.1.4 Návrh modelu**

#### **4.1.5 Evaluace**

#### **4.1.6 Diskuze**

### **4.2 Interpolace vět**

# Závěr

The conclusion is a mandatory part of the bachelor's / diploma thesis. It contains a summary of the work and comments on the degree of fulfillment of the goal, which was set in the work, or summarizes the answers to the questions that were asked in the introduction.

The conclusion to the diploma thesis must be more elaborate - this is stated in more detail in the Requirements of the diploma thesis within the Intranet for FIS students.

The conclusion is perceived as a chapter, which begins on a separate page and is called the conclusion. The name Conclusion is not numbered. The text of the conclusion itself is divided into paragraphs.

## **Přílohy**

## **A. Zdrojové kódy modelů**